

**BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC KIẾN TRÚC ĐÀ NẴNG**

**BÀI HỌC TỪ DIJKSTRA CHO TRIỂN KHAI AI-NATIVE
UNIVERSITY CỦA ĐAU**

**Những nguyên tắc, lỗi cần tránh và checklist kiểm soát khi triển khai Second
Brain, Digital Twin, World Models, AI Tutor và Copilot**

**Phiên bản: V8.5-Đồng nhất nội dung với bộ tài liệu ĐAU AI-native Competency-
Based 5T University (29/5/2026)**

Ngày hiệu chỉnh: 03/06/2026

Đà Nẵng, 2026

Thông tin tài liệu

Trường thông tin	Nội dung
Tên tài liệu	Bài học từ Dijkstra cho triển khai AI-native University của DAU
Mục đích	Cung cấp tài liệu hướng dẫn triển khai thực tế, giúp người đọc tránh sai sót cơ bản và nghiêm trọng khi thiết kế, thí điểm và mở rộng đề án AI-native University.
Phạm vi	Đào tạo, quản trị, bảo đảm chất lượng, nghiên cứu, Second Brain, Digital Twin, World Models, AI Tutor, Copilot, Learning Analytics, Living Portfolio và AI-resistant Assessment.
Đối tượng sử dụng	Lãnh đạo trường, ban chỉ đạo đề án, khoa/chương trình, giảng viên, phòng ban, nhóm kỹ thuật, nhóm bảo đảm chất lượng và đối tác triển khai.
Nguyên tắc biên soạn	Kiến trúc trước - công cụ sau; dữ liệu trước - mô hình sau; governance trước - mở rộng sau; kiểm chứng trước - quyết định sau.

Lưu ý: Tài liệu này là tài liệu chuyên đề phục vụ thiết kế và triển khai đề án. Khi áp dụng vào quy chế chính thức, DAU cần rà soát thêm với các quy định pháp luật, quy định nội bộ, yêu cầu bảo vệ dữ liệu và chuẩn kiểm định hiện hành.

Mục lục

1. Tóm tắt điều hành	17
2. Cơ sở tư tưởng: từ Dijkstra đến AI-native University	18
2.1. Vì sao Dijkstra vẫn liên quan trực tiếp đến AI-native University	18
2.2. Không dùng ẩn dụ sai để thiết kế hệ thống thật	18
2.3. Từ 'debug phần mềm' đến 'debug đại học' - điều tuyệt đối không được làm	19
3. Định nghĩa vận hành AI-native University của DAU	20
3.1. Định nghĩa đề xuất	20
3.2. Những tiêu chí tối thiểu để một cấu phần được gọi là AI-native	20
3.3. Phạm vi triển khai nên bao phủ	21
4. Kiến trúc mục tiêu: từ OBE/CBE đến Second Brain, Digital Twin và World Models	21
4.1. Chuỗi lỗi cần thiết kế trước khi chọn công cụ	21
4.2. Kiến trúc lớp của AI-native University	22
4.3. Phân biệt Dashboard, Digital Twin và World Models	22
5. Nguyên tắc triển khai để tránh sai sót cơ bản	23
5.1. Nguyên tắc 1: Kiến trúc trước, công cụ sau	23
5.2. Nguyên tắc 2: Dữ liệu đúng quan trọng hơn dữ liệu nhiều	23
5.3. Nguyên tắc 3: Không có governance thì không có AI-native	24
5.4. Nguyên tắc 4: Human-in-the-loop là bắt buộc đối với quyết định nhạy cảm	24
5.5. Nguyên tắc 5: Mỗi mô hình phải có Model Card và mỗi dữ liệu lỗi phải có Datasheet	24
5.6. Nguyên tắc 6: Không tách AI khỏi cải tiến liên tục	25
6. Những lỗi nghiêm trọng DAU cần tránh	25
6.1. Lỗi đồng nhất AI-native với chuyển đổi số	25
6.2. Lỗi lấy chatbot làm trung tâm đề án	26
6.3. Lỗi xây World Models trên dữ liệu chưa đủ chuẩn	26
6.4. Lỗi tự động hóa quyết định bất lợi	26
6.5. Lỗi không thiết kế lại assessment trong kỷ nguyên AI	26
6.6. Lỗi không đào tạo lại trực giác của con người	26
7. Khung quản trị dữ liệu, AI và rủi ro	27
7.1. Thiết lập AI Governance Board và các vai trò bắt buộc	27
7.2. Phân tầng rủi ro AI use case	28
7.3. Quản trị dữ liệu: provenance, versioning, quyền truy cập	29
7.4. Nhật ký AI và trách nhiệm giải trình	29
8. Triển khai chi tiết theo cấu phần	29
8.1. Institutional Second Brain	29
8.2. Knowledge Graph năng lực và minh chứng	30
8.3. AI Tutor	30
8.4. Faculty Copilot	30
8.5. Admin Copilot	30
8.6. Research Copilot	31
8.7. Learning Analytics	31
8.8. AI-resistant Assessment và Living Portfolio	31
8.9. Digital Twin và World Models cho quản trị đại học	32
9. Lộ trình triển khai đề xuất	33
9.1. Giai đoạn 0: Chuẩn bị chiến lược và governance	33

9.2. Giai đoạn 1: Chuẩn hóa dữ liệu, ontology và Second Brain	33
9.3. Giai đoạn 2: Pilot các Copilot và AI Tutor có kiểm soát	33
9.4. Giai đoạn 3: Digital Twin cục bộ và Learning Analytics	33
9.5. Giai đoạn 4: World Models có validation	33
9.6. Giai đoạn 5: Mở rộng có kiểm toán và thể chế hóa	33
10. Bộ checklist nghiệm thu trước khi triển khai thực tế	34
10.1. Checklist cho lãnh đạo đề án	34
10.2. Checklist cho khoa/chương trình đào tạo	34
10.3. Checklist cho phòng ban hành chính	34
10.4. Checklist cho nhóm kỹ thuật và nhà cung cấp	35
10.5. Checklist tối thiểu trước khi mở rộng toàn trường	35
11. Khuyến nghị tổ chức triển khai tại DAU	36
11.1. Tổ chức đề án theo danh mục use case, không theo danh mục phần mềm	36
11.2. Lấy một số chương trình/học phần làm 'living lab'	36
11.3. Đầu tư vào năng lực con người ngang với công nghệ	36
11.4. Xây văn hóa 'AI có kiểm chứng'	37
12. Kết luận	37
Tài liệu tham khảo	37

Danh mục bảng

Bảng 1. Chuyển hóa bài học Dijkstra sang nguyên tắc triển khai AI-native University của DAU	15
Bảng 2. Những ẩn dụ và cách hiểu cần tránh khi truyền thông và triển khai đề án	9 15
Bảng 3. Phân biệt số hóa, chuyển đổi số, AI-enhanced và AI-native University	10 15
Bảng 4. Các cấu phần lõi của kiến trúc AI-native University DAU	12 15
Bảng 5. Phân biệt Dashboard, Digital Twin và World Models trong DAU	13 15
Bảng 6. Mẫu Model Card tối thiểu cho World Models và mô hình AI của DAU	14 15
Bảng 7. Ma trận lỗi nghiêm trọng và biện pháp phòng tránh	16 15
Bảng 8. Phân quyền quyết định trong hệ thống AI-native DAU	17 15
Bảng 9. Yêu cầu kiểm soát theo mức rủi ro AI use case	18 15
Bảng 10. Các World Models khởi đầu nên ưu tiên tại DAU	22 15
Bảng 11. Lộ trình triển khai và điều kiện chuyển giai đoạn	23 15
Bảng 12. Tiêu chí Go/No-Go trước khi đưa một cấu phần AI vào vận hành thật	25 15
Bảng 13. Checklist kiểm toán nhanh trước khi nhân rộng AI-native DAU	25 15
Bảng 1. Chuyển hóa bài học Dijkstra sang nguyên tắc triển khai AI-native University của DAU	15
Bảng 2. Những ẩn dụ và cách hiểu cần tránh khi truyền thông và triển khai đề án	15
Bảng 3. Phân biệt số hóa, chuyển đổi số, AI-enhanced và AI-native University	15
Bảng 4. Các cấu phần lõi của kiến trúc AI-native University DAU	15
Bảng 5. Phân biệt Dashboard, Digital Twin và World Models trong DAU	15
Bảng 6. Mẫu Model Card tối thiểu cho World Models và mô hình AI của DAU	15
Bảng 7. Ma trận lỗi nghiêm trọng và biện pháp phòng tránh	15
Bảng 8. Phân quyền quyết định trong hệ thống AI-native DAU	15
Bảng 9. Yêu cầu kiểm soát theo mức rủi ro AI use case	15
Bảng 10. Các World Models khởi đầu nên ưu tiên tại DAU	15
Bảng 11. Lộ trình triển khai và điều kiện chuyển giai đoạn	15
Bảng 12. Tiêu chí Go/No-Go trước khi đưa một cấu phần AI vào vận hành thật	15
Bảng 13. Checklist kiểm toán nhanh trước khi nhân rộng AI-native DAU	15

Danh mục từ viết tắt

Từ viết tắt	Diễn giải
AI	Artificial Intelligence - Trí tuệ nhân tạo
AI-native	Mô hình vận hành được thiết kế lại trên nền AI, dữ liệu, tri thức, mô hình hóa và governance
CBE	Competency-Based Education - Giáo dục dựa trên năng lực
CLO	Course Learning Outcome - Chuẩn đầu ra học phần
CQI	Continuous Quality Improvement - Cải tiến chất lượng liên tục
DAU	Trường Đại học Kiến trúc Đà Nẵng
Digital Twin	Bản sao số mô phỏng cấu trúc, trạng thái và hành vi của hệ thống thật
LLO	Lesson Learning Outcome - Kết quả học tập cấp bài/chủ đề
OBE	Outcome-Based Education - Giáo dục dựa trên chuẩn đầu ra
PI	Performance Indicator - Chỉ báo thực hiện
PLO	Program Learning Outcome - Chuẩn đầu ra chương trình
PO	Program Objective - Mục tiêu chương trình
RAG	Retrieval-Augmented Generation - Sinh câu trả lời có truy xuất nguồn
VQF	Vietnamese Qualifications Framework - Khung trình độ quốc gia Việt Nam
YLO	Year Learning Outcome - Kết quả học tập cấp năm học

1. Tóm tắt điều hành

Tài liệu này được xây dựng như một tài liệu hướng dẫn triển khai dành cho đề án AI-native University của Trường Đại học Kiến trúc Đà Nẵng (DAU). Trọng tâm là xác lập những nguyên tắc đủ chặt để DAU không rơi vào các lỗi nền tảng:

- Đồng nhất AI-native với chuyển đổi số;
- Lấy chatbot làm trung tâm;
- Tự động hóa quyết định nhạy cảm;
- Xây World Models trên dữ liệu chưa chuẩn hóa; hoặc
- triển khai theo kiểu thử-sai trên sinh viên, giảng viên và dữ liệu thật.

Luận điểm xuất phát từ bài giảng nổi tiếng của Edsger W. Dijkstra là: khi một công nghệ thực sự mới xuất hiện, trực giác cũ thường không còn đủ để thiết kế, giảng dạy và vận hành nó. Dijkstra mô tả máy tính như một “radical novelty” và nhấn mạnh rằng **chương trình cần được xây dựng đúng ngay từ cấu trúc**, thay vì chỉ được “debugged into correctness” sau khi sai [1], [2]. Chuyển sang bối cảnh AI-native University, thông điệp đó có nghĩa là **DAU không được triển khai AI bằng ngôn ngữ, quy trình và thói quen của đại học truyền thống** rồi kỳ vọng kết quả sẽ tự nhiên trở thành mô hình đại học mới.

AI-native University, trong tài liệu này, được định nghĩa vận hành là mô hình đại học mà trong đó các quy trình cốt lõi về đào tạo, học tập, đánh giá, nghiên cứu, quản trị, bảo đảm chất lượng, kiểm định và phát triển năng lực được thiết kế lại trên nền dữ liệu, AI, mô hình hóa năng lực, minh chứng học tập, phân tích học tập, Digital Twin, World Models và human-in-the-loop governance. AI-native vì vậy không phải là “đại học có sử dụng AI” mà là đại học có kiến trúc vận hành được tái thiết kế để AI tham gia có kiểm soát vào chu trình nhận biết - suy luận - hỗ trợ quyết định - kiểm chứng - cải tiến liên tục.

Kết luận trọng tâm của tài liệu này là: DAU phải triển khai đề án theo tư duy:

- Kiến trúc trước;
- Dữ liệu trước;
- Quản trị trước;
- Kiểm chứng trước; rồi mới
- Mở rộng công nghệ.

Câu cảnh báo thực hành cần được coi như nguyên tắc xuyên suốt là:

“Không được debug một đại học AI-native bằng sinh viên thật, giảng viên thật, dữ liệu thật và quyết định thật. DAU phải thiết kế đúng từ cấu trúc, kiểm chứng theo từng lớp, thí điểm có kiểm soát, rồi mới mở rộng.”

Bảng 1. Chuyển hóa bài học Dijkstra sang nguyên tắc triển khai AI-native University của DAU

Bài học gốc	Hàm ý đối với DAU	Yêu cầu triển khai thực tế
Công nghệ mới cần ngôn ngữ mới	Không dùng từ vựng chuyển đổi số cũ để mô tả AI-native	Ban hành từ điển khái niệm: AI-native, Second Brain, Digital Twin, World Models, AI Tutor, Copilot, Learning Analytics, Living Portfolio
Không dựa vào trực giác cũ	Không coi AI như chatbot, trợ lý ảo hoặc phần mềm tiện ích	Mỗi câu phân phải có định nghĩa, phạm vi, đầu vào, đầu ra, rủi ro, chủ sở hữu và cơ chế giám sát
Không chỉ debug sau khi sai	Không triển khai thử - sai trên quyết định thật	Thiết lập sandbox, pilot có kiểm soát, validation, audit log, go/no-go criteria trước khi mở rộng
Chương trình cần được xây dựng đúng từ cấu trúc	AI-native phải dựa trên OBE/CBE, VQF, ontology năng lực và evidence	Thiết kế chuỗi LLO-CLO-YLO-PI-PLO-PO-VQF-Assessment-Evidence-CQI trước khi chọn công cụ
Khoảng cách trừu tượng tạo rủi ro	Một chỉ số AI sai có thể kéo theo quyết định sai	Bắt buộc có human-in-the-loop, model card, datasheet, uncertainty, bias test, drift monitoring

2. Cơ sở tư tưởng: từ Dijkstra đến AI-native University

2.1. Vì sao Dijkstra vẫn liên quan trực tiếp đến AI-native University

Điểm có giá trị nhất trong lập luận của Dijkstra không nằm ở câu chuyện kỹ thuật của lập trình, mà nằm ở cách con người nhận thức công nghệ mới. Ông cho rằng máy tính không chỉ là công cụ nhanh hơn của quá khứ mà là một hiện tượng mới có bản chất rời rạc, logic, trạng thái và trừu tượng hóa cực cao [1]. Vì vậy, nếu giáo dục máy tính tiếp tục dạy lập trình như nghề thủ công dựa vào trực giác, kinh nghiệm và thử - sai, hệ quả tất yếu là phần mềm sẽ chứa lỗi ở tầng cấu trúc.

Đề án AI-native University của DAU đối diện một rủi ro tương tự nhưng ở quy mô tổ chức. Nếu DAU triển khai AI như một lớp tiện ích gắn thêm vào LMS, website, hệ thống văn bản, dashboard hay quy trình hành chính sẵn có thì đề án sẽ chỉ đạt mức AI-enhanced, không đạt mức AI-native. Sai lầm nghiêm trọng nhất không phải là lựa chọn sai một công cụ AI, mà là giữ nguyên mô hình đại học truyền thống rồi phủ lên đó một lớp AI.

DAU đã phân biệt rõ giữa việc dùng AI và việc trở thành AI-native University. Dùng AI có thể bắt đầu từ các tác vụ rời rạc: soạn thảo, tìm kiếm, hỏi đáp, tóm tắt, tạo đề cương, phân tích biểu mẫu. Trở thành AI-native đòi hỏi tái cấu trúc:

- Cách DAU tạo, lưu giữ, kiểm chứng và sử dụng tri thức thể chế;
- Cách chương trình đào tạo gắn chuẩn đầu ra với minh chứng;

- Cách dữ liệu học tập được diễn giải thành can thiệp sư phạm;
- Cách World Models mô phỏng các kịch bản; và
- Cách con người chịu trách nhiệm cuối cùng trước mọi quyết định có tác động đến người học.

2.2. Không dùng ẩn dụ sai để thiết kế hệ thống thật

Các ẩn dụ như “AI là giảng viên ảo”, “chatbot là trung tâm trải nghiệm sinh viên”, “dashboard là Digital Twin” hoặc “World Models là máy dự báo tương lai” rất dễ giúp người nghe hiểu nhanh ở mức bề mặt nhưng lại gây hiểu sai ở mức triển khai. Ẩn dụ chỉ nên dùng để dẫn nhập; tài liệu triển khai phải dùng định nghĩa vận hành.

Nếu một khái niệm không chỉ rõ dữ liệu đầu vào, dữ liệu đầu ra, cơ chế kiểm chứng, phạm vi sử dụng, rủi ro và trách nhiệm phê duyệt, thì khái niệm đó chưa đủ điều kiện đưa vào thiết kế hệ thống.

Với DAU, sai lầm về ngôn ngữ có thể trở thành sai lầm về kiến trúc:

- Gọi AI Tutor là “giảng viên ảo” có thể dẫn đến kỳ vọng thay thế vai trò giảng viên;
- Gọi Second Brain là “kho dữ liệu” có thể khiến hệ thống bị thiết kế như nơi chứa file, thay vì hệ tri thức có metadata, ontology, provenance, versioning và liên kết năng lực.
- Gọi Dashboard là Digital Twin có thể làm mất lớp mô hình hóa quan hệ, trạng thái và mô phỏng hành vi của hệ thống.

Bảng 2. Những ẩn dụ và cách hiểu cần tránh khi truyền thông và triển khai đề án

Cách gọi/cách hiểu dễ gây sai	Rủi ro triển khai	Cách diễn đạt nên dùng
AI là giảng viên ảo	Dẫn tới tư duy thay thế giảng viên hoặc giảm trách nhiệm sư phạm	AI Tutor là lớp hỗ trợ học tập cá nhân hóa có kiểm soát bởi giảng viên và cố vấn học tập
Copilot là nhân viên AI	Dễ giao thẩm quyền vượt khả năng kiểm chứng	Copilot là giao diện hỗ trợ tác nghiệp và hỗ trợ quyết định, không phải chủ thể ra quyết định
Second Brain là kho dữ liệu	Biến hệ tri thức thành kho file rời rạc	Institutional Second Brain là hệ tri thức thể chế có cấu trúc, metadata, ontology, provenance và versioning
Digital Twin là dashboard	Chỉ quan sát hiện trạng, không mô hình hóa động lực hệ thống	Digital Twin là bản sao số được cập nhật bằng dữ liệu thật, có khả năng mô phỏng và hỗ trợ quyết định
World Models là máy tiên tri	Tin quá mức vào dự báo, bỏ qua giả định và sai số	World Models là lớp mô phỏng có giả định, dữ liệu, giới hạn, uncertainty và validation

Cách gọi/cách hiểu dễ gây sai	Rủi ro triển khai	Cách diễn đạt nên dùng
Learning Analytics là thống kê điểm	Đánh giá sai năng lực, bỏ qua quá trình và minh chứng	Learning Analytics là phân tích dữ liệu học tập để tạo insight có thể hành động nhằm cải thiện dạy và học

2.3. Từ “debug phần mềm” đến “debug đại học” - điều tuyệt đối không được làm

Trong kỹ thuật phần mềm, Dijkstra phản đối tư duy chỉ sửa lỗi sau khi chạy vì nó tạo ra ảo tưởng rằng hệ thống đã đúng khi chưa phát hiện lỗi [1]. Trong quản trị đại học AI-native, lỗi tương ứng là triển khai đại trà rồi chờ phản hồi để sửa dần, trong khi hệ thống đã tác động đến sinh viên, giảng viên, đánh giá học tập, chất lượng đào tạo và dữ liệu cá nhân.

Do đó, mọi cấu phần AI-native có tác động đến người học hoặc quyết định quản trị phải đi qua bốn vùng an toàn:

- Sandbox kỹ thuật;
- Pilot hạn chế;
- Triển khai có kiểm soát; và
- Mở rộng có kiểm toán.

Một mô hình dự báo rủi ro học tập không được dùng để gắn nhãn sinh viên trước khi được kiểm chứng về độ chính xác, hiệu chuẩn xác suất, thiên lệch, sai số theo nhóm, drift theo thời gian và hiệu quả của can thiệp. Một Admin Copilot không được tự động phát hành quyết định học vụ. Một Research Copilot không được viết thay hoặc tạo trích dẫn không được kiểm chứng.

3. Định nghĩa vận hành AI-native University của DAU

3.1. Định nghĩa đề xuất

AI-native University của DAU là mô hình đại học trong đó AI, dữ liệu, tri thức thể chế, phân tích học tập, mô hình hóa năng lực, mô phỏng hệ thống và governance được thiết kế như các thành phần nền của hoạt động đào tạo - nghiên cứu - quản trị, thay vì là công cụ phụ trợ. Mọi quy trình cốt lõi của nhà trường phải được mô tả bằng dữ liệu, liên kết với chuẩn năng lực, tạo được minh chứng, có thể được phân tích, có thể được mô phỏng, có thể được kiểm toán và luôn giữ con người ở vị trí chịu trách nhiệm cuối cùng.

Định nghĩa này có bốn hệ quả:

- Thứ nhất, AI-native không bắt đầu từ chatbot mà bắt đầu từ kiến trúc dữ liệu - tri thức - năng lực;
- Thứ hai, AI-native không làm giảm vai trò giảng viên mà nâng yêu cầu đối với giảng viên: thiết kế học tập, thiết kế đánh giá, phản biện AI, đọc dữ liệu và hỗ trợ người học dựa trên minh chứng;

- Thứ ba, AI-native không đồng nghĩa với tự động hóa mọi thứ; những quyết định nhạy cảm phải có human-in-the-loop.
- Thứ tư, AI-native phải phục vụ chuẩn đầu ra, chất lượng đào tạo, năng lực thật của người học và trách nhiệm giải trình của nhà trường.

Bảng 3. Các cấp độ phát triển của một đại học số

Cấp độ phát triển	Nội dung	Đặc điểm	DAU cần đạt gì
Cấp 1	Digitized University	Chuyển tài liệu, hồ sơ, quy trình, biểu mẫu, điểm số từ giấy sang dạng số.	Hoàn thiện UMS / LMS / SIS / Portfolio / Khảo thí ở mức dữ liệu có cấu trúc
Cấp 2	Data-informed University	- Tái thiết kế một số quy trình trên nền hệ thống số. - Có dashboard và báo cáo quản trị.	Liên kết dữ liệu đào tạo, khảo thí, tài chính, sinh viên, tuyển sinh
Cấp 3	AI-integrated University	Gắn AI vào các quy trình hiện hữu để tăng tốc hoặc hỗ trợ một số tác vụ dạy học, cố vấn, báo cáo.	- Có Second Brain, Knowledge Graph, World Models - Digital Twin, PDCA số hóa ở mức độ đơn giản; - Triển khai AI Tutor, Faculty Copilot, một số agent pilot
Cấp 4	AI-driven University	Dữ liệu và AI hỗ trợ mạnh việc ra quyết định.	Có Second Brain, Knowledge Graph, World Models - Digital Twin, PDCA số hóa ở mức độ cao
Cấp 5	AI-native University	Mô hình vận hành được thiết kế từ đầu trên nền dữ liệu, AI, chuẩn đầu ra, mô hình năng lực, minh chứng và mô phỏng.	- DAU AI-native Competency-Based 5T University - Second Brain, Knowledge Graph, Digital Twin, World Models, Learning Analytics, Living Portfolio, AI Tutor, các Copilot có governance, CQI dựa trên evidence

3.2. Những tiêu chí tối thiểu để một cấu phần được gọi là AI-native

Một cấu phần trong đề án DAU chỉ nên được gọi là AI-native khi đáp ứng tối thiểu bảy tiêu chí sau:

- Có dữ liệu đầu vào được chuẩn hóa;
- Có liên kết với mục tiêu đào tạo, quản trị hoặc nghiên cứu;
- Có mô hình tri thức hoặc ontology đứng sau;
- Có cơ chế AI hỗ trợ suy luận, khuyến nghị hoặc mô phỏng;
- Có minh chứng hoặc output có thể kiểm chứng;
- Có cơ chế giám sát, ghi log và human-in-the-loop; và
- Có quy trình cải tiến liên tục dựa trên kết quả thực tế.

Những tiêu chí này giúp tránh tình trạng “AI washing”, tức là gắn nhãn AI vào một công cụ thông thường. Một công cụ hỏi đáp văn bản chưa phải AI-native nếu

không biết: (i) tài liệu nào là chính thức; (ii) phiên bản nào đang hiệu lực; (iii) dữ liệu nào được phép truy cập; (iv) câu trả lời nào cần kiểm chứng; và (v) quyết định nào không được tự động hóa. Một dashboard chưa phải AI-native nếu chỉ hiển thị chỉ số mà không kết nối với nguyên nhân, giả định, ngưỡng can thiệp, trách nhiệm xử lý và vòng phản hồi CQI.

3.3. Phạm vi triển khai nên bao phủ

Phạm vi AI-native University của DAU nên bao phủ toàn bộ chuỗi giá trị đại học: (i) tuyển sinh; (ii) nhập học; (iii) thiết kế chương trình; (iv) tổ chức học tập; (v) studio/đồ án; (vi) đánh giá; (vii) cố vấn học tập; (viii) Living Portfolio; (ix) bảo đảm chất lượng; (x) kiểm định; (xi) nghiên cứu khoa học; (xii) công bố; (xiii) quản trị nguồn lực; (xiv) truyền thông; (xv) hợp tác doanh nghiệp và (xvi) phát triển năng lực số - AI của giảng viên, sinh viên, cán bộ quản lý.

Tuy nhiên, bao phủ không có nghĩa là làm tất cả ngay từ đầu. Tư duy triển khai đúng là chọn một số use case có giá trị cao, rủi ro kiểm soát được, dữ liệu đủ tin cậy và có chủ sở hữu rõ ràng; sau đó phát triển thành các cụm năng lực tái sử dụng. Ví dụ, Student Learning Early Warning có thể dùng chung ontology năng lực, dữ liệu học tập, rubric, portfolio evidence và quy trình cố vấn học tập. Accreditation Intelligence có thể dùng cùng Knowledge Graph và evidence repository của Second Brain.

4. Kiến trúc mục tiêu: từ OBE/CBE đến Second Brain, Digital Twin và World Models

4.1. Chuỗi lõi cần thiết kế trước khi chọn công cụ

Đề án AI-native của DAU phải được neo vào chuỗi logic đào tạo dựa trên chuẩn đầu ra. Chuỗi đó có thể được mô tả như sau:

LLO -> CLO -> YLO -> PI -> PLO -> PO -> VQF -> Teaching/Learning Activities -> Assessment -> Rubric -> Evidence -> Living Portfolio -> Learning Analytics -> CQI -> Accreditation Intelligence.

Khung trình độ quốc gia Việt Nam được phê duyệt tại Quyết định 1982/QĐ-TTg, trong đó trình độ đại học thuộc bậc 6 của VQF [12]. Vì vậy, mọi thiết kế AI-native cho đào tạo phải quy chiếu được về năng lực, chuẩn đầu ra và mức trình độ.

Tư duy này tương thích với constructive alignment của Biggs: kết quả học tập dự kiến, hoạt động dạy - học và đánh giá phải được căn chỉnh với nhau [14]. Nó cũng tương thích với logic bảo đảm chất lượng và cải tiến liên tục, nơi chương trình phải thường xuyên đánh giá mức đạt chuẩn đầu ra và dùng kết quả đánh giá làm đầu vào cho hành động cải tiến [13]. AI-native DAU vì vậy không được tách khỏi OBE/CBE; ngược lại, AI-native phải làm cho OBE/CBE trở nên đo được, theo dõi được, cá nhân hóa được và cải tiến được.

4.2. Kiến trúc lớp của AI-native University

Một kiến trúc khả thi cho DAU nên chia thành bảy lớp.

- Lớp 1 là governance và chính sách.

Bài học từ Dijkstra cho triển khai AI-native University của DAU - V8.5 đồng nhất
Dùng cho Hội đồng trường, Ban Giám hiệu, CAIRA-DAU, Phòng Đào tạo, Phòng Khảo thí & ĐBCL, các Khoa/Bộ môn

- Lớp 2 là dữ liệu và định danh.
- Lớp 3 là ontology, Knowledge Graph và Second Brain.
- Lớp 4 là hệ thống tác nghiệp và dữ liệu dòng sự kiện.
- Lớp 5 là analytics, Digital Twin và World Models.
- Lớp 6 là các giao diện AI như AI Tutor, Faculty Copilot, Admin Copilot, Research Copilot.
- Lớp 7 là vòng phản hồi cải tiến liên tục và kiểm định.

Thiết kế theo lớp giúp DAU tránh lỗi xây dựng công cụ/modules trước rồi mới tìm cách tích hợp sau.

Bảng 4. Các cấu phần lõi của kiến trúc AI-native University DAU

Cấu phần	Vai trò	Điều kiện triển khai không được bỏ qua
Data/AI Governance	Thiết lập quyền, trách nhiệm, chuẩn dữ liệu, chính sách AI, phân loại rủi ro	Có hội đồng/phân ban AI governance, quy chế sử dụng AI, decision rights, audit log
Institutional Second Brain	Tập hợp và tổ chức tri thức thể chế	Có metadata, versioning, provenance, quyền truy cập, chuẩn tài liệu chính thức
Knowledge Graph	Liên kết người học, học phần, CLO, PI, PLO, rubric, evidence, chương trình, quy định	Có ontology năng lực và định danh thống nhất
Learning Analytics	Phân tích dữ liệu học tập để tạo insight có thể hành động	Không chỉ phân tích điểm; phải gắn với năng lực, quá trình, portfolio và can thiệp
Digital Twin University	Biểu diễn trạng thái và quan hệ vận hành của các hệ thống trong trường	Cần dữ liệu cập nhật, mô hình quan hệ, khả năng mô phỏng và feedback
World Models	Mô phỏng kịch bản, dự báo có điều kiện và hỗ trợ quyết định	Bắt buộc có assumptions, validation, uncertainty, bias test, drift monitoring
AI Tutor/Copilots	Giao diện hỗ trợ học tập, giảng dạy, hành chính, nghiên cứu	Không tự động quyết định; phải truy xuất nguồn, giới hạn quyền và lưu nhật ký sử dụng
Living Portfolio	Minh chứng động về tiến bộ năng lực của sinh viên	Có rubric, evidence mapping, xác nhận của giảng viên và cơ chế phản biện
Accreditation Intelligence	Hỗ trợ tự đánh giá, minh chứng, CQI và kiểm định	Không tạo minh chứng giả; chỉ tổ chức, kiểm tra, phát hiện khoảng trống và truy xuất evidence

4.3. Phân biệt Dashboard, Digital Twin và World Models

Digital Twin không phải là tên gọi mới của dashboard. Theo cách hiểu hiện đại, Digital Twin là cấu trúc thông tin ảo mô phỏng cấu trúc, ngữ cảnh và hành vi của một hệ thống thật, được cập nhật bằng dữ liệu từ hệ thống thật, có năng lực dự báo và hỗ trợ quyết định; tương tác hai chiều giữa bản sao số và hệ thống thật là yếu tố trung tâm [9].

World Models trong AI lại nhấn mạnh khả năng học biểu diễn nén về môi trường và mô phỏng diễn tiến để hỗ trợ tác nhân AI ra quyết định hoặc lập kế hoạch trong môi trường giả lập trước khi được con người rà soát, kiểm tra và ra quyết định hành động trong thế giới thật [10].

Áp dụng vào DAU:

- Dashboard chỉ trả lời câu hỏi “hiện trạng là gì?”.
- Digital Twin trả lời thêm “các trạng thái và quan hệ vận hành của hệ thống đang diễn ra như thế nào?”.
- World Models trả lời câu hỏi có điều kiện: “nếu can thiệp hoặc bối cảnh thay đổi, điều gì có thể xảy ra, với giả định nào và độ tin cậy ra sao?”.

Bảng 5. Phân biệt Dashboard, Digital Twin và World Models trong DAU

Tiêu chí	Dashboard	Digital Twin	World Models
Câu hỏi chính	Hiện trạng ra sao?	Hệ thống đang vận hành như thế nào?	Nếu điều kiện thay đổi thì điều gì có thể xảy ra?
Dữ liệu	Chỉ số tổng hợp, báo cáo	Dữ liệu trạng thái, quan hệ, sự kiện, dòng vận hành	Dữ liệu lịch sử, trạng thái, hành động, bối cảnh và giả định mô phỏng
Năng lực	Quan sát và cảnh báo	Theo dõi, mô hình hóa, mô phỏng cục bộ	Dự báo có điều kiện, giả lập kịch bản, hỗ trợ lập kế hoạch
Rủi ro	Hiểu sai chỉ số	Mô hình hóa thiếu quan hệ hoặc dữ liệu không đồng bộ	Dự báo sai, quá tin vào mô hình, sim-to-real gap
Điều kiện dừng	Dữ liệu đúng và định nghĩa chỉ số rõ	Dữ liệu cập nhật, mô hình quan hệ, validation	Assumptions, uncertainty, model card, bias test, human approval

5. Nguyên tắc triển khai để tránh sai sót cơ bản

5.1. Nguyên tắc 1: Kiến trúc trước, công cụ sau

DAU không nên bắt đầu bằng câu hỏi “mua nền tảng AI nào”, mà bằng câu hỏi “**kiến trúc năng lực, dữ liệu, tri thức và quyết định của nhà trường là gì?**”. Công cụ chỉ nên được chọn sau khi đã có bản đồ use case, sơ đồ dữ liệu, ontology năng lực, phân loại rủi ro, quy trình phê duyệt, tiêu chí nghiệm thu và kế hoạch tích hợp. Nếu lựa chọn công cụ trước, DAU dễ bị khóa vào logic của nhà cung cấp và buộc phải điều

chỉnh mô hình giáo dục theo phần mềm, thay vì điều chỉnh phần mềm theo mô hình giáo dục.

5.2. Nguyên tắc 2: Dữ liệu đúng quan trọng hơn dữ liệu nhiều

Một hệ AI-native không mạnh vì có nhiều dữ liệu mà vì dữ liệu có cấu trúc, có nguồn gốc, có ngữ cảnh, có quyền truy cập rõ và có thể kiểm chứng.

- Dữ liệu điểm số không đủ để đánh giá năng lực.
- Dữ liệu LMS không đủ để hiểu học tập nếu không gắn với thiết kế học tập.
- Portfolio không có rubric và xác nhận không đủ làm evidence.
- Dữ liệu văn bản không có phiên bản và trạng thái hiệu lực sẽ làm chatbot trả lời sai hoặc trộn quy định cũ với quy định mới.

DAU cần áp dụng tư duy tương tự **“datasheets for datasets”**: mỗi tập dữ liệu quan trọng phải có mô tả về nguồn gốc, mục đích, thành phần, quy trình thu thập, giới hạn, chất lượng, quyền truy cập, rủi ro thiên lệch và khuyến nghị sử dụng [16].

5.3. Nguyên tắc 3: Không có governance thì không có AI-native

NIST AI RMF 1.0 tổ chức quản trị rủi ro AI theo bốn chức năng cốt lõi: Govern, Map, Measure và Manage [3]. ISO/IEC 42001:2023 cung cấp cách tiếp cận hệ thống quản lý AI cho tổ chức, nhấn mạnh việc quản lý rủi ro và cơ hội của AI trong bối cảnh tổ chức [5]. Với DAU, hai nguồn tham chiếu này gợi ý rằng **đề án AI-native phải có khung quản trị trước khi mở rộng ứng dụng**: ai sở hữu dữ liệu, ai duyệt mô hình, ai chịu trách nhiệm khi AI sai, dữ liệu nào không được đưa vào công cụ bên ngoài, quyết định nào bắt buộc con người phê duyệt, sự cố AI được báo cáo ra sao.

Governance không phải lớp thủ tục hành chính để làm chậm đổi mới. Governance là điều kiện để đổi mới được mở rộng an toàn. Không có governance, AI-native sẽ trở thành tập hợp các thử nghiệm rời rạc, khó kiểm toán, khó nhân rộng và dễ gây rủi ro về chất lượng, pháp lý, đạo đức và danh tiếng.

5.4. Nguyên tắc 4: Human-in-the-loop là bắt buộc đối với quyết định nhạy cảm

Trong môi trường đại học, nhiều AI use case có thể ảnh hưởng đến quyền lợi người học, đánh giá giảng viên, phân bổ nguồn lực hoặc danh tiếng chương trình. EU AI Act xem một số hệ thống AI trong giáo dục là high-risk khi chúng có thể quyết định quyền tiếp cận giáo dục hoặc lộ trình nghề nghiệp, ví dụ hệ thống chấm điểm thi [8]. Dù DAU không trực tiếp chịu điều chỉnh của EU AI Act trong phạm vi nội địa, cách tiếp cận dựa trên rủi ro này là tham chiếu rất quan trọng.

Nguyên tắc vận hành là: AI được phép đề xuất, cảnh báo, mô phỏng, tổng hợp và tạo phương án; con người có thẩm quyền phải xem xét, phản biện và quyết định đối với mọi tác động nhạy cảm. Đặc biệt, không được để AI tự động kết luận sinh viên yếu, giảng viên không đạt, học phần thất bại, chương trình không bảo đảm chất lượng hoặc hồ sơ kiểm định đã đầy đủ.

5.5. Nguyên tắc 5: Mỗi mô hình phải có Model Card và mỗi dữ liệu lỗi phải có Datasheet

Model Cards được đề xuất như một cách chuẩn hóa thông tin về mục đích sử dụng, dữ liệu, đánh giá hiệu năng, giới hạn và bối cảnh phù hợp của mô hình học máy [15]. Với World Models và các mô hình dự báo trong DAU, model card không phải là tài liệu phụ; nó là điều kiện triển khai. Nếu không thể trả lời mô hình dùng dữ liệu gì, dự báo điều gì, sai số ra sao, có thiên lệch theo nhóm nào, khi nào không được dùng và ai phê duyệt, thì mô hình chưa đủ điều kiện đưa vào quyết định vận hành.

Bảng 6. Mẫu Model Card tối thiểu cho World Models và mô hình AI của DAU

Nhóm thông tin	Nội dung bắt buộc	Câu hỏi kiểm tra
Định danh	Model ID, phiên bản, chủ sở hữu, ngày phát hành, ngày rà soát	Có biết chính xác đang dùng mô hình nào không?
Mục đích	Use case, đối tượng sử dụng, quyết định được hỗ trợ	Mô hình sinh ra để hỗ trợ việc gì và không hỗ trợ việc gì?
Dữ liệu	Nguồn dữ liệu, thời kỳ dữ liệu, chất lượng, thiếu hụt, quyền sử dụng	Dữ liệu có đúng, đủ, hợp pháp và có provenance không?
Đầu ra	Dạng output, thang đo, ý nghĩa, cách diễn giải	Output là dự báo, khuyến nghị hay bằng chứng?
Đánh giá	Accuracy, calibration, fairness, robustness, drift, uncertainty	Mô hình đã được kiểm chứng bằng dữ liệu độc lập chưa?
Giới hạn	Trường hợp không dùng, nhóm dữ liệu yếu, giả định	Khi nào mô hình có thể sai nghiêm trọng?
Rủi ro	Tác động đến sinh viên, giảng viên, chương trình, pháp lý, đạo đức	Sai số có thể gây hại cho ai?
Giám sát	Audit log, cảnh báo drift, quy trình báo cáo sự cố	Ai phát hiện, ai xử lý và ai chịu trách nhiệm khi mô hình sai?
Human approval	Vai trò phê duyệt, ngưỡng bắt buộc xem xét	Quyết định nào không được tự động hóa?

5.6. Nguyên tắc 6: Không tách AI khỏi cải tiến liên tục

AI-native DAU phải phục vụ PDCA/CQI chứ không phải chỉ tạo ra hiệu ứng trình diễn. Các hệ thống phân tích học tập và World Models phải trả lời được:

- Dữ liệu nào chỉ ra khoảng trống năng lực;
- Khoảng trống đó liên quan CLO/PI/PLO nào;
- Can thiệp nào đã thực hiện;
- Can thiệp có tạo cải thiện không;
- Minh chứng nào chứng minh cải thiện;
- Bài học nào được cập nhật vào chương trình, học phần, rubric, studio hoặc chính sách hỗ trợ sinh viên.

Nếu AI chỉ tạo báo cáo đẹp nhưng không làm thay đổi thiết kế dạy học, đánh giá và hỗ trợ người học, hệ thống sẽ không tạo giá trị học thuật. AI-native đúng nghĩa phải đóng vòng:

**Quan sát -> Phân tích -> Can thiệp -> Đánh giá tác động -> Cải tiến chương trình
-> Cập nhật tri thức thể chế.**

6. Những lỗi nghiêm trọng DAU cần tránh

6.1. Lỗi đồng nhất AI-native với chuyển đổi số

Đây là lỗi nền tảng nhất. Chuyển đổi số có thể tạo điều kiện cho AI-native, nhưng không tự động dẫn đến AI-native. Một trường đại học có LMS, ERP, cổng thông tin, hồ sơ điện tử và dashboard vẫn có thể vận hành theo mô hình truyền thống nếu dữ liệu không liên kết với chuẩn năng lực, nếu đánh giá không tạo evidence tin cậy, nếu AI chỉ làm chức năng hỏi đáp, nếu quyết định không dựa trên mô hình kiểm chứng.

6.2. Lỗi lấy chatbot làm trung tâm đề án

Chatbot là phần dễ nhìn thấy nên thường được dùng để truyền thông nhanh. Tuy nhiên, nếu chatbot trở thành biểu tượng trung tâm, đề án sẽ bị hiểu hẹp. Lỗi của AI-native University không phải là chatbot mà là Second Brain, Knowledge Graph, Data/AI Governance, OBE/CBE Core, Digital Twin, World Models, Living Portfolio, Learning Analytics, IQA/CQI và các Copilot có kiểm soát.

6.3. Lỗi xây World Models trên dữ liệu chưa đủ chuẩn

World Models cần dữ liệu trạng thái, quan hệ, sự kiện, hành động và kết quả.

Nếu dữ liệu học tập, assessment, rubric, portfolio, hồ sơ chương trình, phản hồi doanh nghiệp và dữ liệu cố vấn học tập chưa được chuẩn hóa, mô hình dự báo chỉ tạo ra ảo giác chính xác. Rủi ro lớn nhất là mô hình có vẻ hợp lý trên dashboard nhưng không đúng về học thuật hoặc không công bằng với một nhóm sinh viên.

6.4. Lỗi tự động hóa quyết định bất lợi

AI không được tự động đưa ra quyết định bất lợi đối với sinh viên hoặc giảng viên. Các tác vụ như cảnh báo học vụ, đánh giá rủi ro không đạt chuẩn đầu ra, xếp loại mức hỗ trợ, đánh giá chất lượng giảng dạy, phân tích năng lực chương trình, rà soát minh chứng kiểm định đều cần phân tầng rủi ro. Tín hiệu AI chỉ nên là đầu vào cho cố vấn, giảng viên, hội đồng chuyên môn hoặc đơn vị chức năng xem xét.

6.5. Lỗi không thiết kế lại assessment trong kỷ nguyên AI

Nếu DAU đưa AI Tutor và Copilot vào học tập nhưng vẫn giữ assessment chỉ dựa trên sản phẩm cuối, bài viết nộp cuối kỳ hoặc bài tập dễ thuê/nhờ AI làm thay, hệ thống sẽ khuyến khích sinh viên tạo sản phẩm đẹp nhưng không tạo năng lực thật.

Assessment trong AI-native University phải chuyển từ kiểm tra sản phẩm cuối sang đánh giá quá trình, minh chứng, năng lực trình bày, phản biện, oral defense,

studio critique, portfolio, nhật ký học tập và sản phẩm gắn bối cảnh.

6.6. Lỗi không đào tạo lại trực giác của con người

Một hệ AI-native thất bại không nhất thiết vì mô hình yếu, mà vì con người dùng mô hình bằng trực giác cũ.

- Giảng viên có thể dùng AI để soạn nội dung nhanh nhưng chưa biết thiết kế AI-resistant assessment.
- Cán bộ quản lý có thể đọc dashboard như sự thật khách quan mà không hiểu uncertainty.
- Sinh viên có thể dùng AI như đường tắt thay vì công cụ học tập.
- Lãnh đạo có thể xem dự báo như kết luận thay vì như kịch bản có điều kiện.

UNESCO AI Competency Framework for Teachers nhấn mạnh các năng lực về tư duy lấy con người làm trung tâm, đạo đức AI, nền tảng và ứng dụng AI, sự phạm AI và phát triển nghề nghiệp với AI [7]. DAU nên phát triển chương trình AI-native literacy theo vai trò, không đào tạo đại trà kiểu 'hướng dẫn dùng công cụ'.

Bảng 7. Ma trận lỗi nghiêm trọng và biện pháp phòng tránh

Lỗi cần tránh	Hệ quả có thể xảy ra	Biện pháp phòng tránh
Xem AI-native là chuyển đổi số cộng AI	Đề án bị hạ cấp thành dự án phần mềm	Ban hành định nghĩa vận hành và architecture blueprint
Chatbot-centered	Truyền thông nông, kỳ vọng sai, hệ thống lỗi không được đầu tư	Đặt Second Brain, Knowledge Graph, OBE/CBE và governance làm lõi
Vendor-first	Bị khóa vào sản phẩm, khó tích hợp, khó kiểm soát dữ liệu	Thiết kế yêu cầu nghiệp vụ, dữ liệu và rủi ro trước khi mời giải pháp
Data swamp	Dữ liệu nhiều nhưng không dùng được, mô hình sai	Chuẩn hóa metadata, provenance, ontology, datasheet
Dashboard = Digital Twin	Chỉ quan sát, không mô phỏng, không hỗ trợ quyết định động	Phân tầng dashboard, twin, model; xác định chức năng mỗi lớp
World Models không validation	Dự báo sai nhưng có vẻ khoa học	Model card, holdout validation, calibration, fairness, drift, uncertainty
AI tự quyết định nhạy cảm	Rủi ro pháp lý, đạo đức, chất lượng và danh tiếng	Human-in-the-loop, phân quyền quyết định, audit log
Assessment không kháng AI	Sinh viên đạt điểm nhưng không đạt năng lực	Oral defense, process evidence, portfolio, studio critique, rubric theo PI/PLO
Không đào tạo theo vai trò	Người dùng hiểu sai và lạm dụng AI	AI literacy theo nhóm: lãnh đạo, phòng ban, giảng viên, cố vấn, sinh viên

7. Khung quản trị dữ liệu, AI và rủi ro

7.1. Thiết lập AI Governance Board và các vai trò bắt buộc

DAU cần một cơ chế governance có thẩm quyền thực tế, không chỉ là nhóm kỹ thuật. Cấu trúc khuyến nghị gồm:

- Ban chỉ đạo AI-native University;
- Hội đồng/tiểu ban Data & AI Governance;
- Nhóm kiến trúc dữ liệu và Knowledge Graph;
- Nhóm bảo đảm chất lượng và OBE/CBE;
- Nhóm an toàn thông tin và pháp chế;
- Nhóm sự phạm AI;
- Nhóm triển khai use case tại khoa/phòng; và
- Nhóm kiểm toán nội bộ đối với mô hình, dữ liệu, minh chứng.

Vai trò tối thiểu gồm: AI System Owner, Data Owner, Data Steward, Model Owner, Process Owner, Human Approver, Risk Reviewer, Security Officer, Academic Integrity Officer và QA Evidence Owner. Một use case không có chủ sở hữu rõ thì không nên đưa vào pilot.

Bảng 8. Phân quyền quyết định trong hệ thống AI-native DAU

Loại quyết định/tác vụ	AI được phép làm	Con người bắt buộc phê duyệt
Hỏi đáp quy định, học vụ, tài liệu	Truy xuất, tóm tắt, gợi ý nguồn, nêu mức tin cậy	Phê duyệt nội dung chính thức, xử lý trường hợp ngoại lệ
Cảnh báo học tập	Tính tín hiệu rủi ro, giải thích yếu tố liên quan, đề xuất can thiệp	Cố vấn học tập/giảng viên xác nhận và lựa chọn can thiệp
Đánh giá năng lực	Hỗ trợ đối chiếu evidence với rubric, phát hiện thiếu minh chứng	Giảng viên/hội đồng đánh giá quyết định kết quả
Đánh giá giảng viên / học phần	Tổng hợp dữ liệu, phát hiện bất thường, nêu giả thuyết	Khoa/phòng chuyên môn phân tích nguyên nhân và quyết định cải tiến
Tự đánh giá kiểm định	Tổ chức evidence, phát hiện khoảng trống, kiểm tra liên kết	Hội đồng tự đánh giá xác nhận minh chứng và nhận định
Nghiên cứu khoa học	Gợi ý literature, cấu trúc, kiểm tra citation, hỗ trợ phân tích	Tác giả chịu trách nhiệm nội dung, dữ liệu, lập luận, trích dẫn và liên chính

7.2. Phân tầng rủi ro AI use case

DAU nên phân loại use case thành bốn mức. Mức 0 là tác vụ hỗ trợ cá nhân có rủi ro thấp, ví dụ tóm tắt tài liệu công khai. Mức 1 là tác vụ hỗ trợ quy trình nội bộ nhưng không tác động trực tiếp đến quyền lợi, ví dụ gợi ý cấu trúc báo cáo. Mức 2 là tác vụ hỗ trợ quyết định có ảnh hưởng vừa, ví dụ cảnh báo thiếu evidence trong học

phần. Mức 3 là tác vụ nhạy cảm, có thể ảnh hưởng đến sinh viên, giảng viên, chương trình hoặc dữ liệu cá nhân, ví dụ cảnh báo nguy cơ không đạt chuẩn đầu ra, đánh giá rủi ro học vụ, chấm điểm tự động, phân tích hiệu quả giảng dạy.

Mỗi mức phải có yêu cầu khác nhau về dữ liệu, phê duyệt, log, kiểm thử, giải thích và giám sát. Mức 3 không được triển khai nếu chưa có model card, đánh giá rủi ro, pilot, human-in-the-loop và quy trình khiếu nại/đính chính.

Bảng 9. Yêu cầu kiểm soát theo mức rủi ro AI use case

Mức	Mức rủi ro	Ví dụ	Yêu cầu kiểm soát tối thiểu
Mức 0	Thấp	Tóm tắt tài liệu công khai, hỗ trợ soạn nháp cá nhân	Hướng dẫn sử dụng, không đưa dữ liệu nhạy cảm, người dùng tự kiểm tra
Mức 1	Trung bình thấp	Hỗ trợ viết báo cáo, phân loại văn bản nội bộ	Nguồn dữ liệu được phép, log cơ bản, người dùng xác nhận trước khi phát hành
Mức 2	Trung bình	Phân tích evidence gap, gợi ý cải tiến học phần	Data steward, validation nghiệp vụ, reviewer chuyên môn, audit log
Mức 3	Cao	Cảnh báo học vụ, dự báo đạt PLO, hỗ trợ chấm điểm, đánh giá giảng viên	Risk assessment, model card, bias/fairness test, human approval, appeal/rectification, monitoring

7.3. Quản trị dữ liệu: provenance, versioning, quyền truy cập

- Mỗi dữ liệu dùng cho AI phải trả lời được năm câu hỏi:
 - Dữ liệu đến từ đâu;
 - Ai chịu trách nhiệm;
 - Phiên bản nào đang hiệu lực;
 - Dữ liệu được phép dùng cho mục đích gì; và
 - Kết quả sử dụng dữ liệu có thể được kiểm toán không.
- Các nguồn dữ liệu chính của DAU gồm:
 - Hồ sơ chương trình;
 - Đề cương học phần;
 - Chuẩn đầu ra;
 - Rubric;
 - Bài nộp, đồ án/studio;
 - Portfolio;
 - LMS, SIS;
 - Phản hồi sinh viên, phản hồi doanh nghiệp;
 - Kết quả khảo sát;
 - Minh chứng kiểm định; và
 - Văn bản quản trị.

Cần phân biệt dữ liệu chính thức, dữ liệu nháp, dữ liệu lịch sử, dữ liệu cá nhân, dữ liệu nhạy cảm, dữ liệu công khai và dữ liệu không được đưa vào công cụ AI bên ngoài. Không được để một mô hình RAG hoặc chatbot truy xuất đồng thời văn bản hết hiệu lực và văn bản đang hiệu lực mà không có metadata về trạng thái pháp lý/nội bộ của tài liệu.

7.4. Nhật ký AI và trách nhiệm giải trình

Mọi tương tác AI trong các use case chính thức nên có nhật ký phù hợp với mức rủi ro: (i) người dung; (ii) thời điểm; (iii) hệ thống; (iv) dữ liệu truy xuất; (v) prompt hoặc loại tác vụ; (vi) output; (vii) hành động sau output; (viii) người phê duyệt; và (ix) quyết định cuối cùng. Nhật ký không nhằm giám sát cá nhân một cách cực đoan; mục đích là bảo đảm truy vết, cải tiến, xử lý sự cố và chứng minh trách nhiệm giải trình.

Đối với nghiên cứu khoa học, cần bổ sung AI Use Log: AI đã được dùng ở khâu nào, tạo nội dung gì, phân tích dữ liệu gì, có được kiểm chứng bởi tác giả không, có phù hợp chính sách của tạp chí/hội nghị không. Điều này giúp bảo vệ liêm chính học thuật và tránh tình trạng AI tạo trích dẫn hoặc claim không có cơ sở.

8. Triển khai chi tiết theo cấu phần

8.1. Institutional Second Brain

Institutional Second Brain là nền tri thức của AI-native University.

Second Brain không phải kho lưu trữ file, mà là hệ thống tổ chức tri thức thể chế: (i) văn bản; (ii) quy chế; (iii) chương trình đào tạo; (iv) đề cương học phần; (v) chuẩn đầu ra; (vi) rubric; (vii) minh chứng; (viii) báo cáo tự đánh giá; (ix) kết quả khảo sát; (x) dữ liệu nghiên cứu; (xi) hướng dẫn vận hành; (xii) biên bản cải tiến; và (xiii) các tài liệu chiến lược.

Mỗi tài liệu phải có metadata tối thiểu: (i) loại tài liệu; (ii) đơn vị sở hữu; (iii) phiên bản; (iv) ngày hiệu lực; (v) trạng thái; (vi) phạm vi áp dụng; (vii) quyền truy cập; (viii) liên kết với chuẩn năng lực hoặc quy trình.

Các bước triển khai nên bắt đầu bằng:

- Kiểm kê tài liệu và phân loại tri thức;
- Thiết kế taxonomy và ontology;
- Chuẩn hóa metadata;
- Thiết lập quy trình phê duyệt phiên bản;
- Xây ingestion pipeline;
- Xây RAG có kiểm soát;
- Kiểm thử câu hỏi thực tế; và
- Gắn Second Brain với Knowledge Graph. Lỗi cần tránh là đưa toàn bộ tài liệu lên một hệ thống tìm kiếm rồi gọi đó là Second Brain.

8.2. Knowledge Graph năng lực và minh chứng

Knowledge Graph là lớp liên kết quan hệ giữa các thực thể: chương trình, học phần, CLO, YLO, PI, PLO, PO, VQF, rubric, assessment, evidence, sinh viên, giảng viên, đồ án, studio, hoạt động ngoại khóa, phản hồi doanh nghiệp và báo cáo CQI. Không có Knowledge Graph, AI Tutor và Copilot chỉ trả lời dựa trên văn bản rời rạc; có Knowledge Graph, hệ thống có thể trả lời các câu hỏi theo quan hệ năng lực như: minh chứng nào đang chứng minh PI nào; học phần nào đóng góp PLO nào; sinh viên nào thiếu evidence cho năng lực nào; chương trình nào có khoảng trống assessment.

Bước đầu không cần xây Knowledge Graph toàn trường quá phức tạp. DAU nên chọn một vài chương trình hoặc nhóm học phần làm pilot, chuẩn hóa entity ID cho CLO/PI/PLO/rubric/evidence, rồi mở rộng dần. Điều quan trọng là không thay đổi mã định danh tùy tiện sau khi hệ thống đã vận hành, vì điều đó phá vỡ lineage của dữ liệu.

8.3. AI Tutor

AI Tutor của DAU không nên được thiết kế như công cụ dạy học thay giảng viên mà như lớp hỗ trợ học tập có kiểm soát.

Chức năng phù hợp gồm:

- Giải thích khái niệm theo trình độ người học;
- Gợi ý lộ trình ôn tập theo CLO;
- Đặt câu hỏi gợi mở;
- Phản hồi bản nháp;
- Hỗ trợ tự đánh giá theo rubric;
- Nhắc lịch học tập;
- Đề xuất tài liệu chính thức; và
- Khuyến nghị sinh viên gặp giảng viên/cố vấn học tập khi phát hiện rủi ro.

AI Tutor phải biết giới hạn. Nó (i) không được đưa ra điểm cuối cùng; (ii) không được làm bài thay sinh viên; (iii) không được tự tạo chuẩn đầu ra hoặc quy định; (iv) không được truy cập dữ liệu nhạy cảm vượt quyền; (v) không được kết luận tình trạng học vụ. Nó phải trích xuất từ nguồn chính thức, nêu khi không chắc, khuyến khích sinh viên giải thích lại bằng lời của mình, và tạo dấu vết học tập có thể dùng làm evidence quá trình khi phù hợp.

8.4. Faculty Copilot

Faculty Copilot nên hỗ trợ giảng viên thiết kế và cải tiến học phần, không chỉ hỗ trợ soạn slide hoặc đề cương.

Các chức năng có giá trị cao gồm:

- Rà soát căn chỉnh CLO - assessment - rubric;
- Gợi ý hoạt động học tập theo mức Bloom/DCMS;
- Phát hiện assessment dễ bị AI làm thay;
- Đề xuất oral defense hoặc studio critique;

- Phân tích evidence gap;
- Hỗ trợ phản hồi bản nháp sinh viên;
- Tổng hợp phản hồi lớp học; và
- Gợi ý cải tiến học phần dựa trên dữ liệu.

Giảng viên vẫn chịu trách nhiệm học thuật. Copilot (i) chỉ được đề xuất; (ii) không được tự phê duyệt đề cương; (iii) không được tự sửa chuẩn đầu ra; (iv) không được tự chấm điểm cuối cùng hoặc (v) không được tự kết luận sinh viên đạt/không đạt năng lực. Mọi output của Copilot cần gắn với nguồn hoặc lý do sự phạm để giảng viên có thể kiểm tra.

8.5. Admin Copilot

Admin Copilot có thể hỗ trợ phòng ban trong các tác vụ tổng hợp, kiểm tra, chuẩn hóa văn bản, rà soát quy trình, trả lời câu hỏi nội bộ, phát hiện hồ sơ thiếu, tạo báo cáo và theo dõi tiến độ. Tuy nhiên, rủi ro của Admin Copilot nằm ở chỗ output có thể được hiểu như quyết định hành chính chính thức. Vì vậy, mọi văn bản gửi ra ngoài, thông báo học vụ, kết luận kiểm tra, quyết định liên quan quyền lợi đều phải do người có thẩm quyền duyệt.

Admin Copilot cần được kết nối với Second Brain nhưng phải có phân quyền chặt. Một cán bộ không được dùng Copilot để truy xuất dữ liệu ngoài phạm vi chức trách. Một câu trả lời về quy định phải nêu văn bản nguồn, phiên bản và trạng thái hiệu lực. Nếu có xung đột giữa hai nguồn, hệ thống phải cảnh báo thay vì tự chọn một nguồn.

8.6. Research Copilot

Research Copilot có thể hỗ trợ mạnh cho chiến lược nghiên cứu của DAU:

- Tìm khoảng trống nghiên cứu;
- Xây literature map;
- Gợi ý cấu trúc bài báo;
- Kiểm tra logic lập luận;
- Hỗ trợ phân tích dữ liệu;
- Chuẩn hóa trích dẫn;
- Rà soát chính sách tạp chí;
- Lập kế hoạch công bố; và
- Quản lý dữ liệu nghiên cứu.

Luôn luôn lưu ý rằng Research Copilot cũng dễ tạo rủi ro lớn cho các cá nhân làm nghiên cứu khoa học lệ thuộc vào AI về trích dẫn giả, claim không có nguồn, đạo văn, rò rỉ dữ liệu chưa công bố và nhầm lẫn về quyền tác giả.

Quy tắc triển khai là: AI được hỗ trợ quy trình nghiên cứu, không được thay thế trách nhiệm khoa học của tác giả. Mọi claim quan trọng phải có nguồn kiểm chứng. Mọi dữ liệu nhạy cảm phải tuân thủ Data Management Plan. Mọi sử dụng AI đáng kể

phải được ghi trong AI Use Log nếu chính sách của tạp chí/hội nghị yêu cầu hoặc nếu DAU quy định nội bộ.

8.7. Learning Analytics

SoLAR định nghĩa Learning Analytics là việc thu thập, phân tích, diễn giải và truyền thông dữ liệu về người học và việc học nhằm tạo ra insight có cơ sở lý thuyết và có thể hành động để nâng cao dạy và học [11]. Với DAU, Learning Analytics không được giới hạn ở điểm số, số lượt đăng nhập LMS hoặc tỷ lệ qua môn. Nó phải phân tích tiến bộ năng lực, tương tác học tập, evidence, chất lượng feedback, mức độ đạt CLO/PI/PLO, rủi ro học tập và hiệu quả can thiệp.

Một cảnh báo học tập tốt không chỉ nói 'sinh viên có rủi ro', mà phải chỉ ra rủi ro liên quan năng lực nào, dựa trên dữ liệu nào, độ tin cậy ra sao, có thể sai vì lý do gì và giảng viên/cố vấn nên làm gì tiếp theo. Learning Analytics phải tạo hành động sư phạm, không chỉ tạo báo cáo.

8.8. AI-resistant Assessment và Living Portfolio

AI-resistant Assessment không có nghĩa là cấm AI tuyệt đối. Nó có nghĩa là thiết kế đánh giá sao cho sinh viên phải chứng minh năng lực thật, quá trình thật, hiểu biết thật và khả năng phản biện thật. Các hình thức phù hợp với DAU gồm: (i) studio critique; (ii) oral defense; (iii) nhật ký thiết kế; (iv) bản nháp nhiều vòng; (v) phản biện chéo; (vi) minh chứng hiện trường; (vii) mô hình/sản phẩm vật lý hoặc số; (viii) portfolio; (ix) thuyết minh cá nhân hóa theo bối cảnh địa phương; và (xi) câu hỏi yêu cầu giải thích quyết định thiết kế.

Living Portfolio là nơi tích lũy evidence theo thời gian. Mỗi evidence phải được gắn với rubric, CLO/PI/PLO, mức độ đóng góp cá nhân, phản hồi của giảng viên, phiên bản, quá trình cải tiến và tự phản tỉnh của sinh viên. Nếu portfolio chỉ là nơi trưng bày sản phẩm đẹp, nó không đủ làm nền cho AI-native. Nếu portfolio là hệ evidence có cấu trúc, nó trở thành nguồn dữ liệu quan trọng cho Learning Analytics, cố vấn học tập, kiểm định, tuyển dụng và phát triển năng lực nghề nghiệp.

8.9. Digital Twin và World Models cho quản trị đại học

DAU nên bắt đầu bằng Digital Twin cục bộ trước khi xây World Models toàn trường. Các Twin khả thi gồm:

- Student Learning Twin;
- Course Twin;
- Program Quality Twin;
- Evidence Twin;
- Studio/Project Twin;
- Research Capacity Twin;
- Enrollment/Admissions Twin; và
- Accreditation Readiness Twin.

Mỗi twin cần xác định đối tượng thật, dữ liệu trạng thái, quan hệ, tần suất cập nhật, chỉ số quan sát, kịch bản mô phỏng và người sử dụng.

World Models nên được phát triển theo use case hẹp, có kiểm chứng. Ví dụ:

- Student Learning Early Warning World Model mô phỏng khả năng đạt CLO/PI/PLO dựa trên dữ liệu học tập, assessment, portfolio và can thiệp.
- Course Risk World Model mô phỏng rủi ro một học phần không tạo đủ evidence cho PLO.
- Accreditation Readiness World Model mô phỏng mức sẵn sàng kiểm định dựa trên độ đầy đủ, độ tin cậy và liên kết của minh chứng.

Bảng 10. Các World Models khởi đầu nên ưu tiên tại DAU

World Model	Câu hỏi quản trị/học thuật	Output nên có
Student Learning Early Warning	Sinh viên có nguy cơ không đạt năng lực nào và cần can thiệp gì?	Tín hiệu rủi ro theo CLO/PI/PLO, yếu tố giải thích, khuyến nghị can thiệp, mức tin cậy
Competency Progression Model	Năng lực sinh viên tiến bộ qua các học kỳ ra sao?	Đường tiến bộ năng lực, evidence thiếu, ngưỡng cần hỗ trợ
Course Risk Model	Học phần có đang tạo đủ evidence cho chuẩn đầu ra không?	Evidence gap, rubric risk, assessment misalignment, đề xuất cải tiến
Program Quality Model	Chương trình có rủi ro không đạt PLO/VQF ở điểm nào?	Bản đồ rủi ro PLO, nguyên nhân giả thuyết, kịch bản cải tiến
Accreditation Readiness Model	Hồ sơ kiểm định đã đủ, đúng và liên kết chưa?	Mức sẵn sàng, minh chứng thiếu/yếu, liên kết bị đứt, việc cần làm
Research Capacity Model	Năng lực nghiên cứu của khoa/trường đang phát triển thế nào?	Pipeline đề tài-bài báo-nhóm nghiên cứu, rủi ro chậm tiến độ, đề xuất hỗ trợ
Enrollment Scenario Model	Các kịch bản tuyển sinh ảnh hưởng đến nguồn lực ra sao?	Kịch bản đầu vào, lớp học, giảng viên, tài chính, rủi ro chương trình

9. Lộ trình triển khai đề xuất

9.1. Giai đoạn 0: Chuẩn bị chiến lược và governance

Giai đoạn 0 cần hoàn thành trước khi chọn công cụ lớn. Sản phẩm phải có gồm:

- Tuyên bố định nghĩa AI-native DAU;
- Danh mục use case ưu tiên;
- Phân tầng rủi ro;
- Quy chế sử dụng AI;
- Cấu trúc AI Governance Board;
- Nguyên tắc dữ liệu;
- Quy định human-in-the-loop;

- Khung AI literacy theo vai trò; và
- Tiêu chí go/no-go cho pilot.

Không nên triển khai đại trà khi chưa có các điều kiện này.

9.2. Giai đoạn 1: Chuẩn hóa dữ liệu, ontology và Second Brain

Giai đoạn 1 tập trung vào nền móng. DAU cần:

- Kiểm kê tài liệu;
- Chuẩn hóa metadata;
- Xác định phiên bản hiệu lực;
- Thiết kế ontology năng lực;
- Gắn mã định danh cho chương trình - học phần - CLO - PI - PLO - rubric – evidence; và
- Xây Institutional Second Brain ở phạm vi thí điểm.

Đây là giai đoạn thường bị xem nhẹ vì chưa tạo hiệu ứng trình diễn, nhưng nó quyết định độ tin cậy của toàn bộ AI-native sau này.

9.3. Giai đoạn 2: Pilot các Copilot và AI Tutor có kiểm soát

Giai đoạn 2 nên chọn một số khoa/chương trình/học phần để triển khai AI Tutor, Faculty Copilot, Admin Copilot hoặc Research Copilot. Mỗi pilot phải có: (i) use case rõ; (ii) người dùng rõ; (iii) dữ liệu rõ; (iv) tiêu chí thành công rõ; (v) log; (vi) phản hồi người dung; (vii) đánh giá rủi ro; và (viii) kế hoạch kết thúc hoặc mở rộng.

Pilot không nên đo bằng số lượt dùng, mà bằng cải thiện thực tế: giảm thời gian xử lý, tăng chất lượng feedback, phát hiện evidence gap, cải thiện can thiệp học tập, tăng mức đạt CLO hoặc tăng độ sẵn sàng kiểm định.

9.4. Giai đoạn 3: Digital Twin cục bộ và Learning Analytics

Khi dữ liệu đã đủ chuẩn ở một số vùng, DAU có thể xây các Digital Twin cục bộ và Learning Analytics theo năng lực. Giai đoạn này cần tránh mở rộng quá nhanh. Mục tiêu là chứng minh rằng dữ liệu - mô hình - can thiệp - phản hồi có thể tạo vòng CQI thực sự.

Mỗi Twin phải có chủ sở hữu nghiệp vụ và người chịu trách nhiệm dữ liệu.

9.5. Giai đoạn 4: World Models có validation

Giai đoạn 4 mới nên triển khai World Models có khả năng mô phỏng/dự báo. Mỗi model phải có (i) model card; (ii) dữ liệu huấn luyện/kiểm thử; (iii) đánh giá sai số; (iv) kiểm tra thiên lệch; (v) phân tích uncertainty; (vi) drift monitoring; (vii) quy trình human approval; và (viii) cơ chế phản hồi khi mô hình sai.

Mục tiêu không phải là dự báo hoàn hảo, mà là hỗ trợ ra quyết định tốt hơn, minh bạch hơn và có trách nhiệm hơn.

9.6. Giai đoạn 5: Mở rộng có kiểm toán và thể chế hóa

Chỉ nên mở rộng toàn trường sau khi pilot chứng minh giá trị và rủi ro được kiểm soát. Thể chế hóa bao gồm cập nhật quy chế, quy trình, mô tả công việc, chuẩn năng lực giảng viên, chuẩn dữ liệu, quy trình tự đánh giá, kế hoạch ngân sách, chính sách mua sắm công nghệ, chương trình đào tạo nội bộ và cơ chế kiểm toán định kỳ. AI-native lúc này không còn là dự án, mà trở thành năng lực vận hành của DAU.

Bảng 11. Lộ trình triển khai và điều kiện chuyển giai đoạn

Giai đoạn	Nội dung	Sản phẩm chính	Điều kiện chuyển bước
0	Governance và chiến lược	Định nghĩa, use case map, risk tiers, AI policy, AI Governance Board	Có phê duyệt chính thức, chủ sở hữu và tiêu chí pilot
1	Dữ liệu và Second Brain	Metadata, ontology, evidence map, tài liệu hiệu lực, RAG kiểm soát	Dữ liệu pilot đạt chất lượng, có provenance và phân quyền
2	AI Tutor/Copilot pilot	Use case vận hành, log, phản hồi người dùng, chỉ số giá trị	Chứng minh cải thiện cụ thể và không có rủi ro vượt ngưỡng
3	Digital Twin/Analytics	Twin cục bộ, dashboard năng lực, vòng can thiệp	Dữ liệu cập nhật, can thiệp được theo dõi, CQI đóng vòng
4	World Models	Model card, validation, uncertainty, drift monitoring	Mô hình đạt ngưỡng accuracy/calibration/fairness và được hội đồng duyệt
5	Mở rộng/thể chế hóa	Quy chế, quy trình, ngân sách, đào tạo, kiểm toán	Có governance vận hành thường xuyên và đánh giá định kỳ

10. Bộ checklist nghiệm thu trước khi triển khai thực tế

10.1. Checklist cho lãnh đạo đề án

Lãnh đạo đề án cần xác nhận rằng mỗi câu phần triển khai đều có mục tiêu chiến lược rõ, không chỉ là công nghệ trình diễn. Các câu hỏi bắt buộc gồm:

- Câu phần này phục vụ mục tiêu nào của DAU;
- Liên kết với OBE/CBE và VQF ra sao;
- Dữ liệu đầu vào có đáng tin không;
- Output có thể kiểm chứng không;
- Quyết định nào bị ảnh hưởng;
- Ai chịu trách nhiệm cuối cùng;
- Rủi ro nào là không chấp nhận được;
- Tiêu chí dừng pilot là gì; và
- Bằng chứng nào chứng minh thành công.

10.2. Checklist cho khoa/chương trình đào tạo

Khoa và chương trình cần kiểm tra:

- PLO/PI/CLO có mã định danh thống nhất;
- Học phần có mapping rõ;
- Rubric có mô tả mức đạt;
- Assessment tạo evidence thật;
- Dữ liệu portfolio có xác nhận;
- AI Tutor không làm thay sinh viên;
- Faculty Copilot không tự phê duyệt học thuật;
- Learning Analytics không chỉ dựa trên điểm;
- Can thiệp học tập có người chịu trách nhiệm; và
- Mọi cải tiến được ghi vào CQI log.

10.3. Checklist cho phòng ban hành chính

Phòng ban cần kiểm tra:

- Tài liệu được đưa vào Second Brain có trạng thái hiệu lực;
- Câu trả lời AI có nguồn;
- Dữ liệu cá nhân không bị lộ;
- Copilot không vượt quyền;
- Văn bản đầu ra được duyệt bởi người có thẩm quyền;
- Log được lưu theo chính sách; người dùng biết cách báo cáo lỗi; và có quy trình xử lý khi AI trả lời sai hoặc truy xuất nhầm tài liệu.

10.4. Checklist cho nhóm kỹ thuật và nhà cung cấp

Nhóm kỹ thuật và nhà cung cấp phải chứng minh:

- Kiến trúc tích hợp rõ;
- Dữ liệu không bị khóa kín;
- Có API/export;
- Phân quyền chi tiết;
- Mã hóa và bảo mật;
- Logging;
- Monitoring;
- Đánh giá hiệu năng;
- Khả năng xóa/cập nhật dữ liệu;
- Kiểm thử RAG;
- Kiểm thử hallucination/confabulation;
- Cơ chế chặn dữ liệu nhạy cảm;

- Model card;
- Datasheet; và
- Tài liệu vận hành.

NIST Generative AI Profile nêu nhiều rủi ro đặc thù của GenAI như confabulation, data privacy, harmful bias, information integrity và overreliance, vì vậy các kiểm soát này không thể xem là tùy chọn [4].

Bảng 12. Tiêu chí Go/No-Go trước khi đưa một cấu phần AI vào vận hành thật

Nhóm tiêu chí	Go khi	No-Go khi
Mục tiêu	Use case rõ, có giá trị học thuật/quản trị đo được	Use case mơ hồ, chỉ để trình diễn công nghệ
Dữ liệu	Có provenance, metadata, quyền truy cập, kiểm tra chất lượng	Dữ liệu rời rạc, thiếu phiên bản, không rõ nguồn
Rủi ro	Đã phân tầng, có biện pháp giảm thiểu, có người chịu trách nhiệm	Không có risk assessment hoặc rủi ro cao chưa kiểm soát
Mô hình	Có model card, validation, uncertainty, drift plan	Không biết sai số, không kiểm tra bias, không có giới hạn sử dụng
Quy trình	Có human-in-the-loop, escalation, appeal/rectification	AI tự động quyết định hoặc không có cơ chế sửa sai
Người dùng	Đã đào tạo theo vai trò, có hướng dẫn và kênh hỗ trợ	Người dùng không hiểu giới hạn AI
Nghiệm thu	Có chỉ số giá trị và evidence thành công	Chỉ đo số lượt sử dụng hoặc cảm nhận chung

10.5. Checklist tối thiểu trước khi mở rộng toàn trường

Trước khi mở rộng toàn trường, DAU cần có bằng chứng rằng các pilot đã cải thiện ít nhất một chỉ số có ý nghĩa, ví dụ chất lượng phản hồi học tập, mức độ đầy đủ của evidence, tốc độ xử lý hồ sơ, độ nhất quán rubric, khả năng phát hiện sinh viên cần hỗ trợ, hoặc mức sẵn sàng kiểm định. Đồng thời phải chứng minh rằng không phát sinh rủi ro vượt ngưỡng: không rò rỉ dữ liệu, không quyết định tự động bất lợi, không tạo trích dẫn giả trong nghiên cứu, không dùng quy định hết hiệu lực, không tăng bất bình đẳng trong hỗ trợ sinh viên.

Bảng 13. Checklist kiểm toán nhanh trước khi nhân rộng AI-native DAU

Câu hỏi kiểm toán	Bằng chứng cần có	Đơn vị chịu trách nhiệm
Định nghĩa use case có rõ không?	Use case charter, phạm vi, người dùng, output	Ban chỉ đạo/Process Owner
Dữ liệu có đáng tin không?	Datasheet, metadata, provenance, data quality report	Data Owner/Data Steward
Mô hình có được kiểm chứng không?	Model card, validation report, bias/fairness test	Model Owner/AI Governance
Có human-in-the-loop không?	Decision rights matrix, approval log	Process Owner/Human Approver

Câu hỏi kiểm toán	Bằng chứng cần có	Đơn vị chịu trách nhiệm
Người dùng đã được đào tạo chưa?	Tài liệu hướng dẫn, danh sách tập huấn, bài kiểm tra năng lực	HR/Trung tâm đào tạo nội bộ
Có giá trị thực tế không?	Before-after metrics, user feedback, CQI evidence	Khoa/phòng triển khai
Có cơ chế sửa sai không?	Incident report process, appeal/rectification flow	QA/Pháp chế/IT
Có thể mở rộng bền vững không?	Ngân sách, nhân sự, SLA, kế hoạch bảo trì	Lãnh đạo trường/IT/Đơn vị sở hữu

11. Khuyến nghị tổ chức triển khai tại DAU

11.1. Tổ chức đề án theo danh mục use case, không theo danh mục phần mềm

DAU nên quản lý đề án AI-native như một portfolio các use case có liên kết kiến trúc, thay vì danh mục phần mềm rời rạc. Mỗi use case cần có charter gồm: (i) vấn đề cần giải quyết; (ii) người dung; (iii) dữ liệu; (iv) quy trình hiện tại; (v) quy trình đích; (vi) AI capability; (vii) mức rủi ro; (viii) KPI; (ix) người sở hữu; (x) timeline; (xi) điều kiện nghiệm thu; và (xii) điều kiện dừng. Cách làm này giúp đảm bảo mọi đầu tư công nghệ đều quy về giá trị học thuật hoặc quản trị.

11.2. Lấy một số chương trình/học phần làm “living lab”

DAU nên chọn một số chương trình, học phần studio hoặc đồ án có mức sẵn sàng cao để làm living lab. Lợi thế của các ngành kiến trúc, xây dựng, thiết kế, quy hoạch và mỹ thuật ứng dụng là có sản phẩm, quá trình, phản biện và portfolio rất phù hợp với AI-resistant Assessment và Living Portfolio. Từ living lab, DAU có thể học cách chuẩn hóa evidence, thiết kế rubric, tổ chức phản hồi AI-human, đánh giá oral defense và mô hình hóa tiến bộ năng lực.

11.3. Đầu tư vào năng lực con người ngang với công nghệ

AI-native University đòi hỏi con người cần có các năng lực mới: (i) đọc dữ liệu; (ii) thiết kế đánh giá kháng AI; (iii) viết prompt có trách nhiệm; (iv) kiểm chứng nguồn; (v) hiểu giới hạn mô hình; (vi) sử dụng Copilot trong quy trình chuyên môn; (vii) phản biện dự báo; (viii) quản trị dữ liệu cá nhân; và (ix) ghi nhận ký AI.

DAU nên xây chương trình đào tạo theo vai trò thay vì khóa học chung: lãnh đạo học governance và decision-making; khoa học OBE/CBE analytics; giảng viên học AI pedagogy và assessment; phòng ban học Admin Copilot và dữ liệu; sinh viên học AI literacy, liên chính học thuật và portfolio.

11.4. Xây văn hóa 'AI có kiểm chứng'

Văn hóa quan trọng nhất là không thần thánh hóa AI. Mọi output AI phải được xem như giả thuyết, bản nháp, tín hiệu hoặc khuyến nghị cần kiểm chứng tùy theo use case. Các câu hỏi văn hóa cần được lặp lại trong toàn trường là: (i) nguồn ở đâu; (ii) dữ liệu nào; (iii) mô hình có giới hạn gì; (iv) ai đã kiểm tra; (v) quyết định này có ảnh

hưởng đến ai; (vi) có log không; (vii) có cách sửa sai không; và (viii) bài học này được đưa vào CQI như thế nào.

12. Kết luận

Bài học của Dijkstra đối với DAU không phải là phải biến đề án AI-native thành một hệ thống cứng nhắc, mà là phải tránh triển khai công nghệ mới bằng tư duy cũ. Cái mới cần ngôn ngữ mới, mô hình mới, kỷ luật kiểm chứng mới và cơ chế trách nhiệm mới. Nếu DAU chỉ thêm AI vào quy trình hiện hữu, nhà trường sẽ có một lớp công cụ hiện đại nhưng chưa có mô hình đại học AI-native. Nếu DAU thiết kế lại từ năng lực, dữ liệu, tri thức, minh chứng, mô phỏng và governance, AI có thể trở thành năng lực nền giúp nâng cao chất lượng đào tạo, nghiên cứu, quản trị và kiểm định.

Thông điệp triển khai cuối cùng là: hãy bắt đầu nhỏ nhưng đúng cấu trúc; thí điểm hẹp nhưng kiểm chứng thật; mở rộng chậm nhưng có governance; dùng AI mạnh nhưng không buông trách nhiệm con người; xây World Models nhưng luôn công khai giả định, giới hạn và sai số; phát triển Copilot nhưng không để Copilot thay thế phán đoán chuyên môn; và đặt năng lực thật của sinh viên ở trung tâm của mọi quyết định.

Tài liệu tham khảo

- [1] Dijkstra, E. W. (1988/1989). On the Cruelty of Really Teaching Computing Science (EWD1036). University of Texas at Austin EWD Archive.
<https://www.cs.utexas.edu/users/EWD/ewd10xx/EWD1036.PDF>
- [2] Association for Computing Machinery. (1972). Edsger W. Dijkstra - A.M. Turing Award Laureate: citation and biography.
https://amturing.acm.org/award_winners/dijkstra_1053701.cfm
- [3] National Institute of Standards and Technology. (2023). Artificial Intelligence Risk Management Framework (AI RMF 1.0), NIST AI 100-1.
<https://nvlpubs.nist.gov/nistpubs/ai/nist.ai.100-1.pdf>
- [4] National Institute of Standards and Technology. (2024). Artificial Intelligence Risk Management Framework: Generative Artificial Intelligence Profile, NIST AI 600-1. <https://nvlpubs.nist.gov/nistpubs/ai/NIST.AI.600-1.pdf>
- [5] International Organization for Standardization. (2023). ISO/IEC 42001:2023 Artificial intelligence - Management system. <https://www.iso.org/standard/42001>
- [6] UNESCO. (2023). Guidance for generative AI in education and research.
<https://www.unesco.org/en/articles/guidance-generative-ai-education-and-research>
- [7] UNESCO. (2024). AI competency framework for teachers.
<https://www.unesco.org/en/articles/ai-competency-framework-teachers>
- [8] European Commission. (2026). AI Act: risk-based approach, high-risk systems and implementation timeline. <https://digital-strategy.ec.europa.eu/en/policies/regulatory-framework-ai>
- [9] National Academies of Sciences, Engineering, and Medicine. (2024). Foundational Research Gaps and Future Directions for Digital Twins. National Academies Press. <https://www.ncbi.nlm.nih.gov/books/NBK605502/>
- [10] Ha, D., & Schmidhuber, J. (2018). World Models. arXiv:1803.10122.
<https://arxiv.org/abs/1803.10122>
- [11] Society for Learning Analytics Research. (2025). What is Learning Analytics?
<https://www.solaresearch.org/about/what-is-learning-analytics/>
- [12] Thủ tướng Chính phủ. (2016). Quyết định số 1982/QĐ-TTg ngày 18/10/2016 phê duyệt Khung trình độ quốc gia Việt Nam.
<https://chinhphu.vn/default.aspx?docid=186972&pageid=27160>
- [13] ABET. (2025). Criteria for Accrediting Computing Programs, 2025-2026: Criterion 4 - Continuous Improvement.
<https://www.abet.org/accreditation/accreditation-criteria/criteria-for-accrediting-computing-programs-2025-2026/>

- [14] Biggs, J. B. (1996). Enhancing teaching through constructive alignment. *Higher Education*, 32, 347-364. <https://link.springer.com/article/10.1007/BF00138871>
- [15] Mitchell, M., Wu, S., Zaldivar, A., Barnes, P., Vasserman, L., Hutchinson, B., Spitzer, E., Raji, I. D., & Gebru, T. (2019). Model Cards for Model Reporting. *Proceedings of FAT* 2019*. <https://arxiv.org/abs/1810.03993>
- [16] Gebru, T., Morgenstern, J., Vecchione, B., Vaughan, J. W., Wallach, H., Daume III, H., & Crawford, K. (2021). Datasheets for Datasets. *Communications of the ACM*, 64(12), 86-92. <https://dl.acm.org/doi/10.1145/3458723>
- [17] Trường Đại học Kiến trúc Đà Nẵng - Danang Architecture University (DAU). (2026). Báo cáo tóm tắt điều hành | Chiến lược triển khai DAU AI-native Competency-Based 5T University. Lưu hành nội bộ. Version V8.5 - tháng 5/2026.
- [18] Trường Đại học Kiến trúc Đà Nẵng - Danang Architecture University (DAU). (2026). Tập 00 - Master Guide | Bản đồ tổng thể và cách hiểu đề án DAU AI-native Competency-Based 5T University. Lưu hành nội bộ. Version V8.5 - tháng 5/2026.
- [19] Trường Đại học Kiến trúc Đà Nẵng - Danang Architecture University (DAU). (2026). Chiến lược phát triển Trường Đại học Kiến trúc Đà Nẵng giai đoạn 2026-2030 và tầm nhìn đến năm 2050. Lưu hành nội bộ. Version V8.5 - tháng 5/2026.
- [20] Trường Đại học Kiến trúc Đà Nẵng - Danang Architecture University (DAU). (2026). Second Brain và World Models trong kiến trúc AI-native University. Lưu hành nội bộ. Version V8.5 - tháng 5/2026.
- [21] Trường Đại học Kiến trúc Đà Nẵng - Danang Architecture University (DAU). (2026). Diễn giải khoa học và hướng dẫn triển khai công thức chiến lược AI-native Competency-Based DAU. Lưu hành nội bộ. Version V8.5 - tháng 5/2026.